

Finanças Quantitativas

Lista de exercícios 4

Lucas Emanuel Resck Domingues

Maio de 2020

Problema 3.17 [1]

1.

$$\begin{aligned} e^{\sigma^2/2} \mathbb{E}\{f(Z + \sigma)\} &= e^{\sigma^2/2} \int_{-\infty}^{\infty} f(z + \sigma) f_Z(z) dz \\ &= e^{\sigma^2/2} \int_{-\infty}^{\infty} f(w) f_Z(w - \sigma) dw \\ &= e^{\sigma^2/2} \int_{-\infty}^{\infty} f(z) f_Z(z - \sigma) dz \\ &= e^{\sigma^2/2} \int_{-\infty}^{\infty} f(z) \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{(z - \sigma)^2}{2}\right\} dz \\ &= \int_{-\infty}^{\infty} f(z) \frac{1}{\sqrt{2\pi}} \exp\{-z^2/2 + z\sigma\} dz \\ &= \int_{-\infty}^{\infty} f(z) e^{z\sigma} f_Z(z) dz \\ &= \mathbb{E}\{f(Z) e^{Z\sigma}\} \end{aligned}$$

$$\begin{aligned} \mathbb{E}\{e^X\} &= \mathbb{E}\{e^{\mu + \sigma Z}\} \\ &= e^{\mu} \mathbb{E}\{1 \cdot e^{\sigma Z}\}, \quad f \equiv 1 \\ &= e^{\mu} e^{\sigma^2/2} \mathbb{E}\{1\} \\ &= e^{\mu + \sigma^2/2} \end{aligned}$$

2.

$$\begin{aligned}
\mathbb{E}\{e^X h(Y)\} &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^x h(y) f_{X,Y}(x, y) dx dy \\
&= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^x h(y + \text{cov}\{X, Y\}) f_{X,Y}(x, y + \text{cov}\{X, Y\}) dx dy \\
&\vdots \\
&= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^x h(y + \text{cov}\{X, Y\}) f_X(x) f_Y(y) dx dy \\
&= \int_{-\infty}^{\infty} e^x f_X(x) dx \int_{-\infty}^{\infty} h(y + \text{cov}\{X, Y\}) f_Y(y) dy \\
&= \mathbb{E}\{e^X\} \mathbb{E}\{h(Y + \text{cov}\{X, Y\})\}
\end{aligned}$$

Problema 3.18 [1]

1. Sabemos que $Y = \log X \sim N(\mu, \sigma^2)$, logo:

$$\begin{aligned}
f_X(x) &= f_Y(y) \left| \frac{dy}{dx} \right| \\
&= f_Y(\log x) \left| \frac{d}{dx}(\log x) \right| \\
&= f_Y(\log x) \left| \frac{1}{x} \right| \\
&= \frac{1}{x\sigma\sqrt{2\pi}} \exp \left[-\frac{(\log x - \mu)^2}{2\sigma^2} \right], \quad x > 0
\end{aligned}$$

2, 3. Chamemos ρ o coeficiente de correlação *Pearson* entre $X \sim \text{Lognormal}(0, 1)$ e $Y \sim \text{Lognormal}(0, \sigma^2)$. Então queremos calcular:

$$\rho = \frac{\text{cov}\{X, Y\}}{\sigma_X \sigma_Y} = \frac{\mathbb{E}\{XY\} - \mathbb{E}\{X\} \mathbb{E}\{Y\}}{\sqrt{\text{var}\{X\} \text{var}\{Y\}}}$$

Vamos calcular cada um desses termos. Se $Z_1 = \log X$ e $Z_2 = \log Y$, então $\mathbf{Z} = (Z_1, Z_2)$ têm distribuição normal multivariada. Vejamos a *moment-generating function* da distribuição normal multivariada:

$$\begin{aligned}
M_{\mathbf{Z}}(\mathbf{t}) &= \mathbb{E}\{e^{\mathbf{t}^T \mathbf{Z}}\} \\
&= \mathbb{E}\{e^{t_1 \log X + t_2 \log Y}\} \\
&= \mathbb{E}\{X^{t_1} Y^{t_2}\}
\end{aligned}$$

Então $M_{\mathbf{Z}}((1, 1)) = \mathbb{E}\{XY\}$. Através da expressão da *m.g.f* da normal multivariada, encontramos:

$$\begin{aligned}\mathbb{E}\{XY\} &= M_{\mathbf{Z}}((1, 1)) \\ &= \exp\left\{\mu^T \mathbf{t} + \frac{1}{2} \mathbf{t}^T \Sigma \mathbf{t}\right\} \\ &= \exp\left\{\frac{1}{2} (1 + \sigma^2 + 2a)\right\}, \quad a = \text{cov}\{Z_1, Z_2\}\end{aligned}$$

De maneira análoga, é possível calcular $\mathbb{E}\{X\} = e^{\frac{1}{2}}$ e $\mathbb{E}\{Y\} = e^{\frac{\sigma^2}{2}}$. Encontramos também $\text{var}\{X\} = (e - 1)e$ e $\text{var}\{Y\} = (e^{\sigma^2} - 1)e^{\sigma^2}$, a partir dos valores esperados e da definição de variância. Então encontramos ρ :

$$\begin{aligned}\rho &= \frac{\mathbb{E}\{XY\} - \mathbb{E}\{X\}\mathbb{E}\{Y\}}{\sqrt{\text{var}\{X\} \text{var}\{Y\}}} \\ &= \frac{\exp\left\{\frac{1}{2} (1 + \sigma^2 + 2a)\right\} - e^{\frac{1}{2}} e^{\frac{\sigma^2}{2}}}{\sqrt{(e - 1)e(e^{\sigma^2} - 1)e^{\sigma^2}}} \\ &= \frac{e^a - 1}{\sqrt{(e - 1)(e^{\sigma^2} - 1)}}\end{aligned}$$

Como $a = \text{cov}\{Z_1, Z_2\}$, encontramos máximo e mínimo para a :

$$\begin{aligned}-1 &\leq \frac{\text{cov}\{Z_1, Z_2\}}{\sigma_{Z_1} \sigma_{Z_2}} \leq 1 \\ -1 &\leq \frac{\text{cov}\{Z_1, Z_2\}}{\sigma} \leq 1 \\ -\sigma &\leq \text{cov}\{Z_1, Z_2\} \leq \sigma\end{aligned}$$

Sendo assim, concluímos:


$$\begin{aligned}\rho_{\min} &= \frac{e^{-\sigma} - 1}{\sqrt{(e - 1)(e^{\sigma^2} - 1)}} \\ \rho_{\max} &= \frac{e^{\sigma} - 1}{\sqrt{(e - 1)(e^{\sigma^2} - 1)}}\end{aligned}$$

4.

$$\begin{aligned}\lim_{\sigma \rightarrow \infty} \rho_{\min} &= \frac{e^{-\sigma} - 1}{\sqrt{(e - 1)(e^{\sigma^2} - 1)}} \\ &= 0\end{aligned}$$

$$\begin{aligned}
\lim_{\sigma \rightarrow \infty} \rho_{\max} &= \frac{e^{\sigma} - 1}{\sqrt{(e - 1)(e^{\sigma^2} - 1)}} \\
&= \frac{1 - 1/e^{\sigma}}{\sqrt{(e - 1)(e^{\sigma^2 - 2\sigma} - 1/e^{2\sigma})}} \\
&= 0
\end{aligned}$$

Podemos ver que esses resultados condizem com as simulações do **Problema 3.10** [1]:



Ou seja, à medida que σ cresce, ρ se aproxima de zero.

Problema 3.24 [1]

```

1. suppressMessages(library(copula))
   Pearson = list()
   Kendall = list()
   Spearman = list()
   RHO = seq(from = 0, to = 1, by = 0.05)
   for(i in 1:length(RHO)) {

```


```

SD = list()
temp = rCopula(2000, normalCopula(RHO[i], 2))
SD$x = temp[,1]
SD$y = temp[,2]
SD_norm = list()
SD_norm$x = qnorm(SD$x)
SD_norm$y = qnorm(SD$y)
Pearson[[i]] = cor(SD_norm$x, SD_norm$y,
                  method = "pearson")
Kendall[[i]] = cor(SD_norm$x, SD_norm$y,
                  method = "kendall")
Spearman[[i]] = cor(SD_norm$x, SD_norm$y,
                   method = "spearman")
}


## Found more than one class "copula" in cache; using the first,
from namespace 'Rsaft'
## Also defined by 'copula'

plot(RHO, Pearson)


```



```
plot(RHO, Kendall)
```




```
plot(RHO, Spearman)
```




Nos três gráficos encontrados, podemos observar que o coeficiente de correlação cresce praticamente de forma linear com o parâmetro ρ da cópula

Gaussiana. ρ descreve a correlação entre as distribuições marginais. Sendo assim, esperamos que as medidas de correlação, que conhecemos, entre as distribuições marginais amostradas tenham valores próximos a ρ .


```
Pearson = list()
Kendall = list()
Spearman = list()
RHO = seq(from = 0, to = 1, by = 0.05)
for(i in 1:length(RHO)) {
  SD = list()
  temp = rCopula(2000, normalCopula(RHO[i], 2))
  SD$x = temp[,1]
  SD$y = temp[,2]
  SD_cauchy = list()
  SD_cauchy$x = qcauchy(SD$x)
  SD_cauchy$y = qcauchy(SD$y)
  Pearson[[i]] = cor(SD_cauchy$x, SD_cauchy$y,
                     method = "pearson")
  Kendall[[i]] = cor(SD_cauchy$x, SD_cauchy$y,
                     method = "kendall")
  Spearman[[i]] = cor(SD_cauchy$x, SD_cauchy$y,
                      method = "spearman")
}
plot(RHO, Pearson)
```



```
plot(RHO, Kendall)
```





```
plot(RHO, Spearman)
```





Com exceção do método *Pearson*, os resultados foram parecidos aos anteriores, e as explicações podem ser consideradas as mesmas. No método *Pearson*, porém, os resultados são muito diferentes. O coeficiente ρ difere bastante do coeficiente de correlação *Pearson*, de modo que o gráfico sequer é crescente. Uma possibilidade é o fato de que o valor esperado de uma distribuição padrão de Cauchy não existe. Sendo assim, não existe a covariância e o coeficiente teórico de correlação *Pearson*, de modo que o coeficiente *Pearson* empírico difere bastante dos outros resultados.


```
2. Pearson = list()
Kendall = list()
Spearman = list()
BETA = seq(from = 1, to = 20, by = 0.5)
for(i in 1:length(BETA)) {
  SD = list()
  temp = rCopula(2000, gumbelCopula(BETA[i], 2))
  if(BETA[i] %% 5 == 0) {
    persp(gumbelCopula(BETA[i], 2), dCopula)
  }
  SD$x = temp[,1]
  SD$y = temp[,2]
  SD_norm = list()
  SD_norm$x = qnorm(SD$x)
  SD_norm$y = qnorm(SD$y)
  Pearson[[i]] = cor(SD_norm$x, SD_norm$y,
                     method = "pearson")
  Kendall[[i]] = cor(SD_norm$x, SD_norm$y,
                    method = "kendall")
  Spearman[[i]] = cor(SD_norm$x, SD_norm$y,
                     method = "spearman")
}

## parameter at boundary ==> returning indepCopula()
## Found more than one class "copula" in cache; using the first,
## from namespace 'Rsaft'
## Also defined by 'copula'
```







```
plot(BETA, Pearson)
```



```
plot(BETA, Kendall)
```



```
plot(BETA, Spearman)
```



A cópula de Gumbel tem uma propriedade interessante: se o valor de β for pequeno, ela se comporta de maneira parecida com uma distribuição uniforme multivariada (ou seja, baixa correlação). Porém, à medida que β cresce, ela obtém o formato que pode ser visto nos gráficos acima. Dessa forma, a correlação entre as marginais cresce muito rápido. Observe que os gráficos correlação vs. β são parecidos entre si.

```
Pearson = list()
Kendall = list()
Spearman = list()
BETA = seq(from = 1, to = 20, by = 0.5)
for(i in 1:length(BETA)) {
  SD = list()
  temp = rCopula(2000, gumbelCopula(BETA[i], 2))
  SD$x = temp[,1]
  SD$y = temp[,2]
  SD_cauchy = list()
  SD_cauchy$x = qcauchy(SD$x)
  SD_cauchy$y = qcauchy(SD$y)
  Pearson[[i]] = cor(SD_cauchy$x, SD_cauchy$y,
                     method = "pearson")
  Kendall[[i]] = cor(SD_cauchy$x, SD_cauchy$y,
                     method = "kendall")
}
```


```

    Spearman[[i]] = cor(SD_cauchy$x, SD_cauchy$y,
                        method = "spearman")
}

## parameter at boundary ==> returning indepCopula()

plot(BETA, Pearson)


```




```

plot(BETA, Kendall)

```



```
plot(BETA, Spearman)
```



Com exceção do método *Pearson*, os resultados foram parecidos aos anteriores. Da mesma forma que no exercício 1, uma das possibilidades para

o método *Pearson* não funcionar bem é pelo fato de que o valor esperado da Cauchy padrão não existe, como explicado anteriormente.

PCA da Estrutura a Termo da Taxa de Juros (ET TJ)

Importamos e verificamos os dados:

```
load("prices_Swap_PRE_DI.RData")
dim(prices_Swap_PRE_DI)

## [1] 3258 11

head(prices_Swap_PRE_DI)

##      date    4_YR    1_MO    5_YR    2_MO    3_MO    4_MO    6_MO    1_YR
## 1 2002-06-11 31.2753 18.4900 31.9320 18.7200 18.8000 18.7000 20.4900 21.4600
## 2 2002-06-12 33.9903 19.7009 34.6484 19.7090 21.4608 22.3382 23.1222 23.0700
## 3 2002-06-13 35.6196 19.3000 36.2747 20.8400 20.5069 21.0466 22.1055 25.4000
## 4 2002-06-14 36.1113 19.4100 36.7636 20.1900 20.5100 22.4500 22.2600 26.1200
## 5 2002-06-17 35.5415 18.7330 36.1825 19.1634 19.6359 20.1083 21.3597 26.4996
## 6 2002-06-18 35.1315 19.8400 35.7739 19.4000 19.9620 20.7211 22.7835 27.4588
##      2_YR    3_YR
## 1 25.9500 28.9500
## 2 27.7000 30.4100
## 3 30.5200 34.0400
## 4 30.8900 33.9800
## 5 30.7251 33.6000
## 6 31.3700 33.7283
```

Estamos lidando com dados observados uma vez por dia, durante 3258 dias, a partir do dia 11/06/2002. São 10 dimensões, cada uma indicando a taxa de juros para um número específico de meses para a maturidade, neste caso 1, 2, 3, 4, 6, 12, 24, 36, 48, e 60 meses. Vamos organizar o dataframe e visualizar os dados:


```
columns = colnames(prices_Swap_PRE_DI)[c(3, 5, 6, 7, 8,
                                           9, 10, 11, 2, 4)]
yield_br = prices_Swap_PRE_DI[, columns]
head(yield_br)

##      1_MO    2_MO    3_MO    4_MO    6_MO    1_YR    2_YR    3_YR    4_YR
## 1 18.4900 18.7200 18.8000 18.7000 20.4900 21.4600 25.9500 28.9500 31.2753
## 2 19.7009 19.7090 21.4608 22.3382 23.1222 23.0700 27.7000 30.4100 33.9903
## 3 19.3000 20.8400 20.5069 21.0466 22.1055 25.4000 30.5200 34.0400 35.6196
## 4 19.4100 20.1900 20.5100 22.4500 22.2600 26.1200 30.8900 33.9800 36.1113
## 5 18.7330 19.1634 19.6359 20.1083 21.3597 26.4996 30.7251 33.6000 35.5415
```



```
## 6 19.8400 19.4000 19.9620 20.7211 22.7835 27.4588 31.3700 33.7283 35.1315
##      5_YR
## 1 31.9320
## 2 34.6484
## 3 36.2747
## 4 36.7636
## 5 36.1825
## 6 35.7739

matplot(yield_br, type = "l", lty = 1)
legend("topright",
      legend = colnames(yield_br),
      lwd = 2,
      col=1:length(colnames(yield_br)),
      cex=0.6)
```



Então podemos realizar a análise de componentes principais (PCA):


```
yield_br.pca = princomp(yield_br)
summary(yield_br.pca)

## Importance of components:
##               Comp.1      Comp.2      Comp.3      Comp.4
## Standard deviation 16.160223  4.20778556  0.904920443  0.2836770043
```

```
## Proportion of Variance 0.933133 0.06326391 0.002925968 0.0002875392
## Cumulative Proportion 0.933133 0.99639692 0.999322886 0.9996104257
##                        Comp.5      Comp.6      Comp.7      Comp.8
## Standard deviation    0.1959801025 1.437544e-01 1.352633e-01 1.321798e-01
## Proportion of Variance 0.0001372375 7.383988e-05 6.537458e-05 6.242792e-05
## Cumulative Proportion 0.9997476632 9.998215e-01 9.998869e-01 9.999493e-01
##                        Comp.9      Comp.10
## Standard deviation    9.100651e-02 0.0768472113
## Proportion of Variance 2.959333e-05 0.0000211011
## Cumulative Proportion 9.999789e-01 1.0000000000
```

Observe que os três primeiros componentes principais explicam 99,9% da variância, sugerindo um "espaço efetivo" de três dimensões. Qualquer curva pode ser bem aproximada por uma combinação linear dos três primeiros componentes.

```
plot(yield_br.pca,
      main = "Proporção da variância explicada pelos componentes")
```



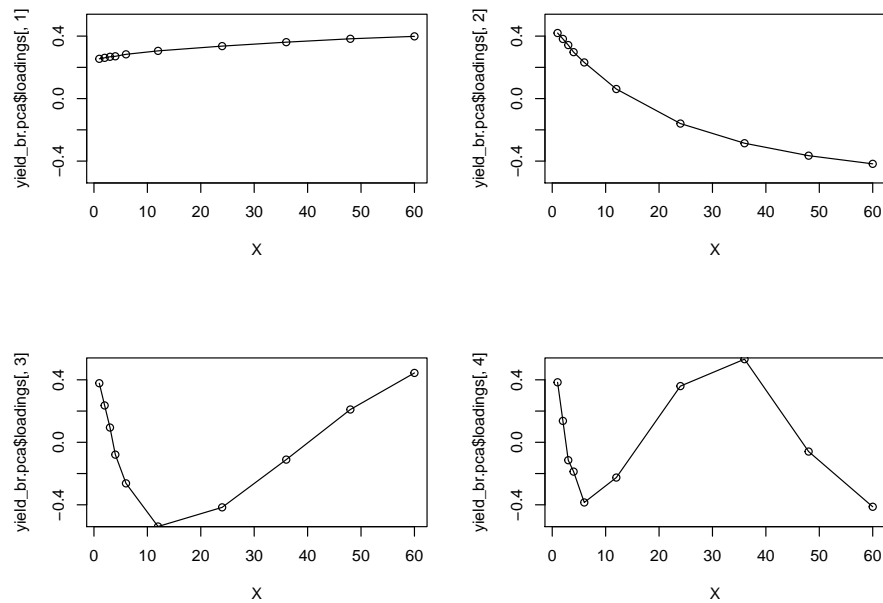
Vejamos agora o *plot* dos *loadings*, ou seja, os autovetores:

```
X = c(1, 2, 3, 4, 6, 12, 24, 36, 48, 60)
par(mfrow = c(2, 2))
plot(X, yield_br.pca$loadings[, 1], ylim = c(-0.5, 0.5))
lines(X, yield_br.pca$loadings[, 1], ylim = c(-0.5, 0.5))
```

```

plot(X, yield_br.pca$loadings[, 2], ylim = c(-0.5, 0.5))
lines(X, yield_br.pca$loadings[, 2], ylim = c(-0.5, 0.5))
plot(X, yield_br.pca$loadings[, 3], ylim = c(-0.5, 0.5))
lines(X, yield_br.pca$loadings[, 3], ylim = c(-0.5, 0.5))
plot(X, yield_br.pca$loadings[, 4], ylim = c(-0.5, 0.5))
lines(X, yield_br.pca$loadings[, 4], ylim = c(-0.5, 0.5))

```



Podemos observar que os gráficos dos primeiros quatro componentes principais resultam como o esperado:

- O primeiro componente é essencialmente constante, de modo que pode ser interpretado como um nível da curva a termos. A intuição é que ele representa os juros médios sobre os vencimentos;
- O segundo componente pode ser interpretado como a tendência da curva a termos, ou seja, se ela cresce ou decresce com o tempo;
- O terceiro representa a curvatura da curva a termos, ou seja, o quanto varia o crescimento ou decrescimento;
- O quarto componente aparentemente não representa nada óbvio.

Referências

[1] Carmona René. *Statistical analysis of financial data in R*. Springer, 2014.