

# Finanças Quantitativas

## Lista de exercícios 6

Lucas Emanuel Resck Domingues

Junho de 2020

### Problema 6.6 [1]

- (i) 1. No lado esquerdo da equação:

$$\begin{aligned}X_t - X_{t-1} &= X_t - BX_t \\ &= (1 - B)X_t\end{aligned}$$

Então concluímos  $\phi(z) = 1 - z$ . Do lado direito:

$$\begin{aligned}W_t - 1,5W_{t-1} &= W_t - 1,5BW_t \\ &= (1 - 1,5B)W_t\end{aligned}$$

Logo,  $\theta(z) = 1 - 1,5z$ . Portanto, o modelo pode ser escrito:

$$\phi(B)X_t = \theta(B)W_t$$

2. O modelo é estacionário desde que a parte AR seja. Se assumimos  $\phi(z) = 0$ , temos  $z = 1$ . Como  $|z| \leq 1$ , o modelo não é estacionário (era necessário  $|z| > 1$ ).

Da mesma forma o modelo é invertível se a parte MA o é. Porém,  $\theta(z) = 0$  implica em  $z < 1$ , de forma que o modelo não é invertível.

- (ii) 1. De forma análoga ao exercício anterior, temos

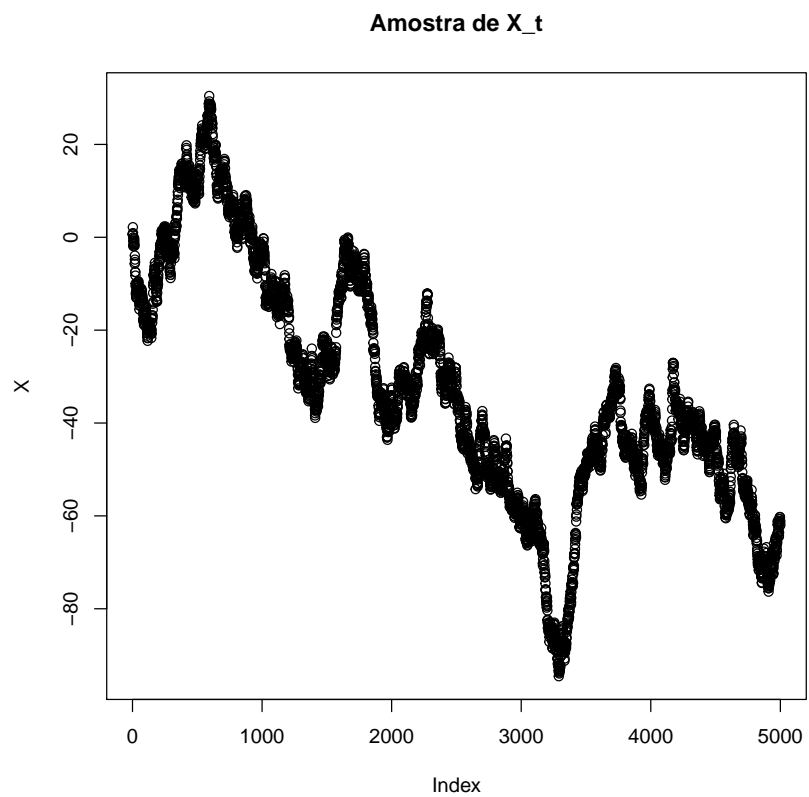
$$\phi(B)X_t = \theta(B)W_t$$

com  $\phi(z) = 1 - 0,8z$  e  $\theta(z) = 1 - 0,5z$

2. Neste caso, para ambos os polinômios,  $|z| > 1$ , de modo que o modelo é estacionário e invertível.

## Problema 6.11 [1]

```
1. N = 5000
fX = function(N) {
  WN = rnorm(N)
  X = c(WN[1])
  for (t in 2:N) {
    X_t = X[length(X)] + WN[t]
    X = c(X, X_t)
  }
  X
}
X = fX(N)
plot(X, main = "Amostra de X_t")
```



```

2. fphi_1 = function(X) {
  n = length(X)
  sum_1 = 0
  sum_2 = 0
  for (i in 2:n) {
    sum_1 = sum_1 + X[i]*X[i-1]
    sum_2 = sum_2 + X[i-1]^2
  }
  sum_1/sum_2
}


fsigma_2 = function(X, phi_1) {
  n = length(X)
  sum = 0
  for (i in 2:n) {
    sum = sum + (X[i] - phi_1*X[i-1])^2
  }
  sum/(n-1)
}

fdf = function(phi_1, sigma_2) {
  (phi_1 - 1)/sqrt(sigma_2)
}


PHI_1 = c()
SIGMA_2 = c()
DF = c()
for (n in 1:N) {
  phi_1 = fphi_1(X[1:n])
  PHI_1 = c(PHI_1, phi_1)
  sigma_2 = fsigma_2(X[1:n], phi_1)
  SIGMA_2 = c(SIGMA_2, sigma_2)
  df = fdf(phi_1, sigma_2)
  DF = c(DF, df)
}

plot(PHI_1)

```



```
plot(SIGMA_2)
```



Ambas as estimativas convergem para seus valores verdadeiros (ou seja, 1).

```
3. N = 1000
   NS = 500
   XX = c()
   QQ = c()
   t = seq(100, N, 10)
   quantiles = c(0.01, 0.02, 0.03, 0.04,
                 0.05, 0.1, 0.25, 0.5,
                 0.75, 0.9, 0.95, 0.96,
                 0.97, 0.98, 0.99)

   for (i in 1:NS) {
     X = fX(N)
     XX = cbind(XX, X)
   }
```

```

for (n in t) {
  q = quantile(XX[n,], quantiles, type=1)
  QQ = cbind(QQ, q)
}

QQ = t(QQ)

dim(QQ)

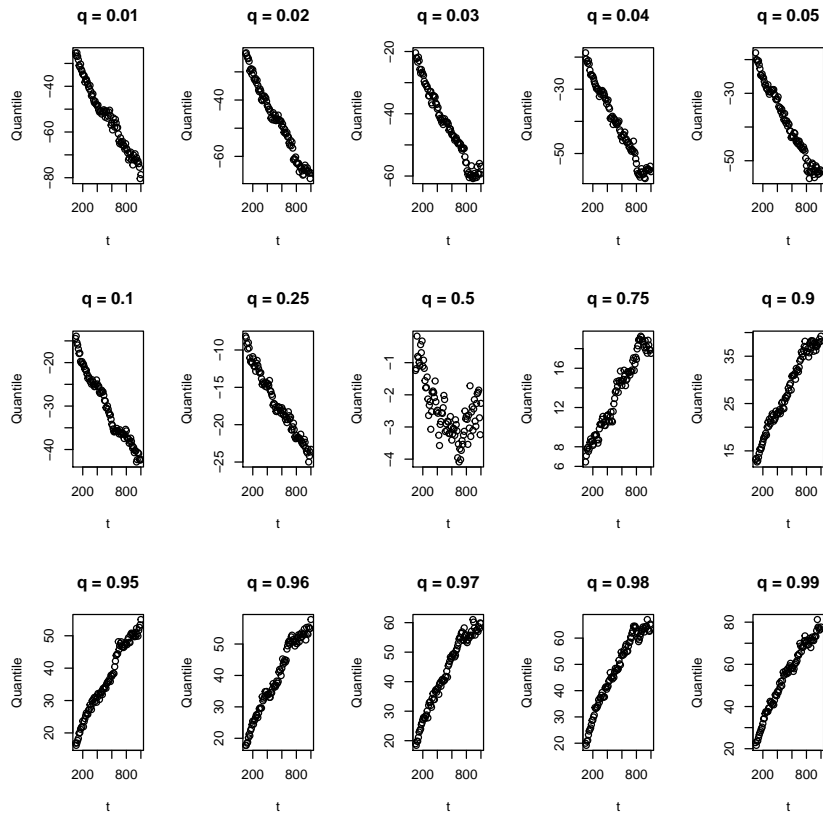
## [1] 91 15

```

```

4. par(mfrow = c(3, 5))
for (i in 1:15) {
  plot(t, QQ[,i], xlab = "t", ylab = "Quantile",
       main = paste0("q = ", quantiles[i]))
}

```



```

5. proxy = QQ[dim(QQ)[1],]

suppressMessages(library(quantmod))
suppressWarnings(suppressMessages(getSymbols("CPN")))

## [1] "CPN"

head(CPN)

##           CPN.Open CPN.High CPN.Low CPN.Close CPN.Volume CPN.Adjusted
## 2012-06-18    16.14    16.34    16.11    16.33    3684281         16.33
## 2012-06-19    16.33    16.47    16.29    16.41    2611352         16.41
## 2012-06-20    16.44    16.44    16.21    16.33    2419812         16.33
## 2012-06-21    16.31    16.34    16.01    16.04    3306956         16.04
## 2012-06-22    16.15    16.17    16.02    16.05    3557785         16.05
## 2012-06-25    16.01    16.06    15.90    15.97    2397340         15.97

dim(CPN)

## [1] 2005      6

CPN = CPN$CPN.Close
CPN = CPN[!is.na(CPN)]
CPNLRet = diff(log(CPN))
CPNLRet = CPNLRet[2:length(CPNLRet)]

```

Para CPN:

```

X = as.vector(CPN)
phi_1 = fphi_1(X)
sigma_2 = fsigma_2(X, phi_1)
df = fdf(phi_1, sigma_2)
proxy

##           1%           2%           3%           4%           5%           10%           25%
## -78.639800 -65.859243 -56.881600 -55.659585 -53.075828 -42.279639 -23.301486
##           50%           75%           90%           95%           96%           97%           98%
## -2.266289  17.513441  39.239656  55.014411  57.795559  59.710879  64.945140
##           99%
##  77.689146

df

## [1] 0.0006092523

```

Portanto, não rejeitamos o passeio aleatório com nível 1%. Para CPNL-Ret:

```
X = as.vector(CPNLRet)
phi_1 = fphi_1(X)
sigma_2 = fsigma_2(X, phi_1)
df = fdf(phi_1, sigma_2)
proxy
```

##	1%	2%	3%	4%	5%	10%	25%
##	-78.639800	-65.859243	-56.881600	-55.659585	-53.075828	-42.279639	-23.301486
##	50%	75%	90%	95%	96%	97%	98%
##	-2.266289	17.513441	39.239656	55.014411	57.795559	59.710879	64.945140
##	99%						
##	77.689146						

```
df

## [1] -41.12455
```

Também não rejeitamos para esse nível. Agora verificamos o *augmented DF*:

```
library(tseries)
adf.test(CPN)

##
## Augmented Dickey-Fuller Test
##
## data: CPN
## Dickey-Fuller = -0.7708, Lag order = 11, p-value = 0.9642
## alternative hypothesis: stationary

adf.test(CPNLRet)

## Warning in adf.test(CPNLRet): p-value smaller than printed
p-value

##
## Augmented Dickey-Fuller Test
##
## data: CPNLRet
## Dickey-Fuller = -9.0467, Lag order = 11, p-value = 0.01
## alternative hypothesis: stationary
```



Neste caso, rejeitamos a hipótese de passeio aleatório com nível 1% apenas para o CPNLRet. Ou seja, a série de log retorno parece ser estacionária.

### Problema 6.13 [1]

1.

$$\begin{aligned} X_t &= \mu + X_{t-1} + W_t \\ &= \mu + (\mu + X_{t-2} + W_{t-1}) + W_t \\ &= t\mu + x_0 + \sum_{i=1}^t W_i \end{aligned}$$

2.

$$\begin{aligned} \mathbb{E}\{X_t\} &= \mathbb{E}\left\{t\mu + x_0 + \sum_{i=1}^t W_i\right\} \\ &= t\mu + x_0 \end{aligned}$$

$$\begin{aligned} \text{var}\{X_t\} &= \text{var}\left\{t\mu + x_0 + \sum_{i=1}^t W_i\right\} \\ &= \text{var}\left\{\sum_{i=1}^t W_i\right\} \\ &= \sum_{i=1}^t \text{var}\{W_i\} \quad (W_i \text{ são i.i.d.}) \\ &= t\sigma^2 \end{aligned}$$

$$\begin{aligned} \gamma(s, t) &= \text{cov}\{X_s, X_t\} \\ &= \text{cov}\left\{s\mu + x_0 + \sum_{i=1}^s W_i, t\mu + x_0 + \sum_{i=1}^t W_i\right\} \\ &= \text{cov}\left\{\sum_{i=1}^s W_i, \sum_{i=1}^t W_i\right\} \\ &= \sum_{i=1}^s \sum_{j=1}^t \text{cov}\{W_i, W_j\} \\ &= \sum_{i=1}^{\min(s, t)} \text{cov}\{W_i, W_i\} \\ &= \min(s, t)\sigma^2 \end{aligned}$$

3.  $\{X_t\}_t$  não é estacionário, pois as estatísticas, particularmente média e variância, mudam com o tempo.

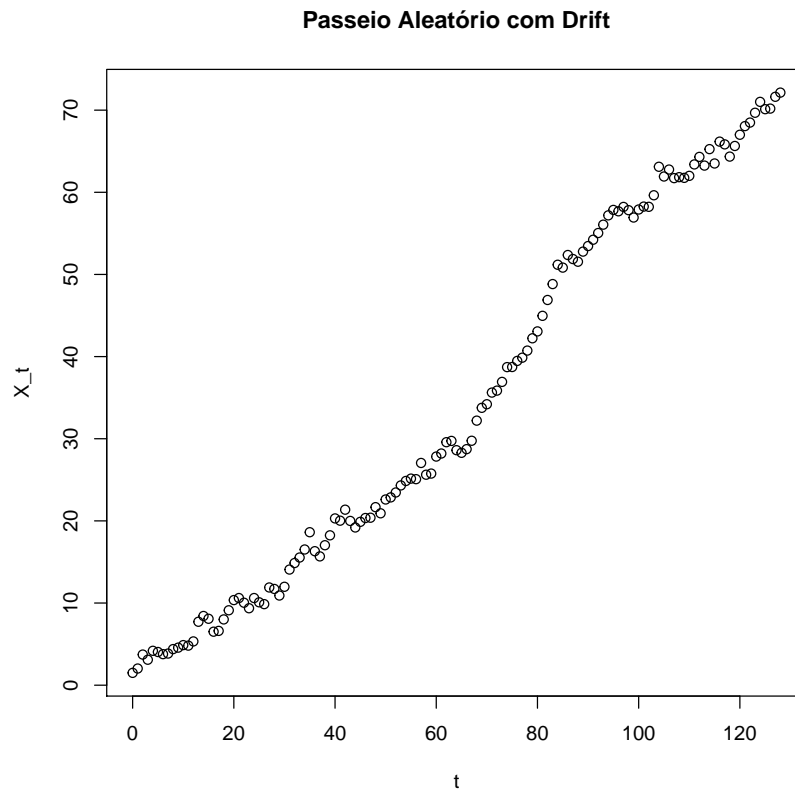
4.

$$\begin{aligned}\nabla X_t &= X_t - X_{t-1} \\ &= t\mu + x_0 + \sum_{i=1}^t W_i - \left[ (t-1)\mu + x_0 + \sum_{i=1}^{t-1} W_i \right] \\ &= \mu + W_t\end{aligned}$$

$$\begin{aligned}\gamma(s, t) &= \text{cov}\{\nabla X_s, \nabla X_t\} \\ &= \text{cov}\{\mu + W_s, \mu + W_t\} \\ &= \text{cov}\{W_s, W_t\} \\ &= \begin{cases} \sigma^2, & s = t \\ 0, & s \neq t \end{cases}\end{aligned}$$

5. Como  $W_i$  são i.i.d,  $W_i + \mu$  também o são, logo o processo  $\{\nabla X_t\}$  é estacionário.


```
6. x_0 = 1.5
mu = 0.5
n = 128
WN = rnorm(n)
X = c(x_0)
par(mfrow = c(1, 1))
for (i in 1:n) {
  X = c(X, mu + X[length(X)] + WN[i])
}
plot(seq(0, n), X, main = "Passeio Aleatório com Drift",
      xlab = "t", ylab = "X_t")
```




Observe que  $x_0$  representa o ponto inicial do passeio aleatório. No valor esperado,  $\mathbb{E}\{X_t\} = t\mu + x_0$ , logo  $x_0$  e  $\mu$  podem ser interpretados como os parâmetros de uma função linear que aproxima esses dados.

```
plot(seq(0, n), X, main = "Passeio Aleatório com Drift",  
     xlab = "t", ylab = "X_t")  
abline(x_0, mu)
```

**Passeio Aleatório com Drift**



```
plot(X[1:length(X)-1], X[2:length(X)])
```



Um *lag plot* de *lag* 1 nos mostra dados muito próximos de uma reta identidade. Isso mostra que, de certa forma,  $X_{t-1}$  é muito importante para o cálculo de  $X_t$ , porém isso é óbvio pois é a definição do modelo. Na verdade, estamos plotando  $X_{t-1}$  vs.  $\mu + X_{t-1} + W_t$  e verificamos que o resultado é muito próximo de uma identidade deslocada por  $\mu$  com ruído de média zero.

## Referências

- [1] Carmona René. *Statistical analysis of financial data in R*. Springer, 2014.